

CUAI 리서치 NLP1팀 최종 발표

2025.11.25

발표자 : 양희원

목차

1. 연구 배경

- 기존 RAG의 한계
- 문제 정의

2. HVDR 프레임워크

- 핵심 아이디어
- 수학적 기초 (MDP)
- 시스템 아키텍처

3. 연구 방법론

- 강화학습 훈련 (MAPPO)
- 데이터셋 선택 전략

4. 진행 현황

- Phase 1: 가설 검증 결과 (완료)
- Phase 2: 환경 구축 현황
- 데이터셋 탐색

5. 연구 계획

- 연구 질문 및 가설
- 향후 일정

6. 기대 효과 및 결론

1. 연구 배경 - 기존 RAG의 한계

기본 RAG 시스템의 가정

- 모든 문서 청크의 사전 확률 $p(d)$ = 균일 분포
- "모든 정보는 동일하게 중요하다"

이로 인한 한계


- 검색 정밀도 저하
- 복잡한 질의에 대한 추론 실패
- 비효율적인 문서 탐색



기존 접근법의 시도

- HRAG: 계층 구조 활용
 - GraphRAG: 지식 그래프 활용
- 정적 구조 + 규칙 기반으로 한계 존재

2. HVDR 프레임워크 : 핵심 아이디어



핵심 차별점

- 학습 가능한 가치 함수 (규칙 ×)
- 동적 의사결정 (정적 구조 ×)
- 종단간 최적화 (단계별 최적화 ×)

2. HVDR 프레임워크 : 수학적 기초


2단계 마르코프 결정 과정

구성 요소	Planning 단계	Searching 단계
State	$s_{\text{plan}} = [q_{\text{emb}}, \text{meta}(q)]$	$s_{\text{search}} = [q_{\text{emb}}, \{d_i\}]$
Action	도메인 선택	문서 집합 선택
Reward	(에피소드 종료 시)	RAGAS 기반 평가

하이브리드 검색 점수

$$s'(q, d) = \underset{\substack{\uparrow \\ \text{의미적 유사도}}}{\alpha} \times \text{semantic_sim}(q, d) + (1-\alpha) \times \underset{\substack{\uparrow \\ \text{구조적 사전확률}}}{p(d)}$$

2. HVDR 프레임워크 : 아키텍처



3. 강화학습 훈련 : MAPPO

다중 에이전트 강화학습

알고리즘 : MAPPO (Multi-Agent PPO)

- V_plan 에이전트 + V_search 에이전트
- 공유 보상, 독립 최적화

훈련 프로세스

1. 궤적 수집

현재 정책으로 전체 파이프라인 실행
(도메인 선택 → 문서 선택 → 답변 생성)

2. 보상 계산

$$\text{RAGAS} = \lambda_1 \cdot \text{Faithfulness} + \lambda_2 \cdot \text{Completeness} + \lambda_3 \cdot \text{Relevance}$$

3. 정책 업데이트

- Actor: PPO clipped objective
- Critic: MSE loss

4. 진행 현황 : Phase 1- 가설 검증 결과 (완료)

검증 목표 : "가치 함수가 최종 보상을 학습할 수 있는가?"

실험 설계

- 미니어처 RAG 환경 (3개 도메인, 100개 쿼리)
- Oracle 보상 함수 (정답 채점기)
- 지도학습으로 가치 함수 훈련

결과 : 가치 함수 학습 가능성 입증

정책	평균 보상	성능
Baseline	0.34	1.0×
Learned HVDR	0.99	2.9×

4. 진행 현황 : Phase 2 - 환경 구축

RAPTOR 계층 트리 구축

Level 3 (Root) [1개 요약]



Level 2 [2개 요약]



Level 1 [5개 요약]



Level 0 [10개 Leaf Chunks]

총 18개 노드

구조적 사전 확률 $p(d)$ 계산

$$p(d) = 0.7 \times (\text{깊이}/\text{최대깊이}) + 0.3 \times \log(1+\text{자식수})$$

결과:

- Level 0 (leaf): $p(d) \approx 0.10$
- Level 1: $p(d) \approx 0.45$
- Level 2: $p(d) \approx 0.82$
- Level 3 (root): $p(d) \approx 1.00$

4. 진행 현황 : 데이터셋 탐색

HVDR 데이터셋 요구사항

- 계층 구조
- 엔티티 간 관계
- Multi-hop reasoning
- 증거 문서 간 연결

후보	카테고리	데이터셋	주요 특징
	법률	LLeQA	법전→조문 완벽 계층
	법률	KoBLEX	한국어, multi-hop
	범용	UDA	3도메인, ablation 용이
	범용	RAGBench	10만 예제, 5도메인
	추론	HotpotQA	Evidence chain 제공
	추론	MuSiQue	GraphRAG 벤치마크

5. 연구 계획 : 연구 질문 및 가설

RQ1. 구조적 사전 확률의 효과

가설 : $s'(q,d)$ 사용 시 Precision@k, MRR 향상

평가 : LLeQA, UDA 데이터셋

RQ2. 2단계 에이전트의 효율성

가설 : Multi-hop 질의에서 GraphRAG보다 빠르고 정확

평가 : HotpotQA, MuSiQue + Latency, EM/F1

RQ3. 가치 모델 vs 규칙 기반

가설 : 충실성↑, 완전성↑, 환각↓

평가 : RAGBench + RAGAS 점수

5. 연구 계획 : 진행 상황 종합 및 연구 일정

Phase	상태	진행률	주요 성과
Phase 1	완료	100%	가치 함수 학습 검증 (2.9배↑)
Phase 2-1	완료	95%	RAPTOR + p(d) + 환경 구축
Phase 2-2	다음	0%	V_plan/V_search 구현
Phase 2-3	대기	0%	MAPPO 훈련
데이터셋	진행	60%	8개 후보 분석 완료



1주 [O] 환경 설정 + 데이터 준비
 1주 [] 데이터셋 최종 결정 + 전처리 ← 현재
 2-3주 [] V_plan/V_search 모델 구현
 3-4주 [] MAPPO 파이프라인 구축 및 훈련
 2주 [] 평가 및 분석 (베이스라인 비교)
 1-2주 [] 결과 정리 및 보고서 작성

6. 기대 효과

학술적 기여

- 검색을 명시적 가치 의사결정으로 공식화
- 에이전트 기반 RAG의 새로운 패러다임 제시
- 계획-탐색 분리를 통한 해석 가능성 향상

기술적 기여

- 구조적 정보 + 강화학습의 유기적 결합
- 종단간 학습 가능한 검색 시스템
- Multi-hop reasoning 능력 강화

실용적 기여

- 복잡한 질의 처리 능력 향상
- 검색 효율성 개선 (도메인 사전 선택)
- 답변 품질 향상 (충실성, 완전성)

6. 핵심 성과/결론

완료된 작업

- 가치 함수 학습 가능성 입증 (2.9배 향상)
- RAPTOR 트리 구축 완료
- 구조적 사전 확률 $p(d)$ 계산 구현
- 하이브리드 검색 점수 설계
- 2단계 MDP 환경 구현
- 8개 데이터셋 후보 분석

진행중

- Phase 2-1 디버깅
- 데이터셋 최종 결정

다음 단계

- $V_{\text{plan}}/V_{\text{search}}$ 모델 구현
- MAPPO 훈련 파이프라인

감사합니다