

CUAI NLP Research 2팀

2025.11.4

발표자: 이나현

팀 소개

이나현
조민지
태아카

100지선다 MCQA

- MCQA의 태생적 한계: 객관식 문제는 찍어서 맞출 확률이 존재함 (예: 4지선다 → 25%).
- Long-form의 한계: 자유서술형 문제는 평가가 어렵고 자동 채점이 까다로움.
- 핵심 아이디어:
만약 MCQA의 선지를 100개 이상으로 늘리면, "찍기"를 통한 정답 확률이 극도로 낮아지면서 사실상 Long-form에 가까운 자유도를 확보할 수 있지 않을까?

실험 계획

1 선지 수에 따른 정답 확률 변화 실험

- 선지 수를 $n = 4, 10, 20, 50, 100$ 으로 변화시킴.
- 무작위 추측 시 한 번 또는 k 번 시도에서의 정답 확률 비교
- 선지 수가 많아질수록 정답 확률은 급감하지만, 여러 시도 시 동일 확률을 유지할 수 있는지 비교.

2 정답 위치(인덱스)에 따른 정답률 편향 실험

- 정답이 선지 1번, 12번, 50번, 99번 등 위치에 따라 정답률이 달라지는가?
- 인간 혹은 모델 응답자들이 특정 위치(앞쪽, 중간, 끝)에 심리적 편향을 가지는지 측정.


3 선지 순서 랜덤화의 영향 실험

- 정답 고정 / 나머지 선지를 섞기
- 순서만 다를 때 정확도가 통계적으로 유의미하게 달라지는가 분석.

연구 개요

MCQA (Multiple Choice Question answering)?

- LLM의 평가 도구
- MCQA의 태생적 한계: 객관식 문제는 찍어서 맞출 확률이 존재함 (예: 4지선다 → 25%).
- Long-form의 한계: 자유서술형 문제는 평가가 어렵고 자동 채점이 까다로움.



```
#55
question
Find the degree for the given field extension
 $\mathbb{Q}(\sqrt{2})$  over  $\mathbb{Q}$ .

subject
abstract_algebra

choices
[ "0", "2", "1", "3" ]

answer
1 B
```

MMLU example




Figure 1: Accuracy of DeepSeek-R1 (light purple) and Gemini-2.5-Pro (dark) on KSM, KMMLU-Pro, and KAIO.

연구 개요: 100지선다 MCQA

Then, what if ..

- 찍어서 맞출 확률이 극히 낮아질 만큼 선지의 숫자를 늘려보는 건 어떨까?
- 이렇게 되면, MCQA의 장점을 살리면서 Long Form Question만큼의 효용을 낼 수 있지 않을까?

What is the value of
 $7 + 8$?

- | | |
|--------|--------|
| 1. 9 | 11. 19 |
| 2. 10 | 12. 20 |
| 3. 11 | 13. 21 |
| 4. 12 | 14. 22 |
| 5. 13 | 15. 23 |
| 6. 14 | 16. 24 |
| 7. 15 | 17. 25 |
| 8. 16 | 18. 26 |
| 9. 17 | 19. 27 |
| 10. 18 | 20. 99 |

연구 계획

- ‘맞춤법’문제로 정의
 - ex. ‘다음 중 맞춤법이 옳은 것은?’ ... 이어서 선지 100개

데이터셋 확보

- 네이버사전, 국립국어원 등 국어사전에서 예문을 모아 ‘옳은 문장’으로 130개의 선지 마련.
- 이후, 틀린 선지를 만들기 위해 LLM을 사용해 사소한 맞춤법을 무너뜨림.

∴ 다음 중 맞춤법이 옳은 문장은? / 옳지 않은 문장?

1. 병원 측은 더 이상의 방법이 없다며 나머지는 하늘에 맡기자고 했다.
2. 이 제품은 다른 나라에서 만든 수입품보다 품질이 월등히 우수하다.
3. 하지만 마약의 익명성과 은폐성을 고려할 때 실제 중독자 수는 40배에 이를 것으로 추산되고 있습니다.
4. 그 사내는 입고 있는 옷이며, 얼굴에 난 사마귀, 손에 있는 흉터까지 우리 형하고 똑같았다.
5. 가위에 눌린 그는 꿈에서 깨어나기 위해 엄지발가락을 움짱대기 시작했다.
6. 그녀는 친구에게 자신의 일기를 내보이며 자신의 속마음을 전하려 했다.
7. 눈만 오면 강아지처럼 쏘다니던 동네 아이들도 별 수 없이 집 안에 갇혀 창밖만 바라보고 있었습니다.
8. 대통령제는 행정부와 입법부를 분리시켜 대등한 관계를 유지하는, 이른바 견제와 균형의 원리에 충실한 제도이다.
9. 넓은 잔디에 군데군데 심은 노랑 팬지꽃이 수많은 나비 떼가 내려앉아 날개를 펴고 있는 것처럼 보였다.

연구 계획

사용 모델

- Gemini-2.5-flash, pro
- deepseek R1, qwen3 thinking, phi4 reasoning
- HyperclovaX-think, kanana-8B .. 등등

연구 계획

실험 계획

1. 선지 수에 따른 정답 확률 변화 실험

- 선지 수를 $n = 4, 10, 20, 50, 100$ 으로 변화시킴.
- 한 번 또는 k 번 시도에서의 정답 확률 비교
- 선지 수가 많아질수록 정답 확률은 급감하지만, 여러 시도 시 동일 확률을 유지할 수 있는지 비교.

2. 정답 위치(인덱스)에 따른 정답률 편향 실험

- 정답이 선지 1번, 12번, 50번, 99번 등 위치에 따라 정답률이 달라지는가?

3. 선지 순서 랜덤화의 영향 실험


- 정답은 특정 번호에 고정 / 나머지 선지를 섞기
- 선지의 순서가 달라질 때 정확도가 통계적으로 유의미하게 달라지는가? (만약 달라진다면, 선지의 분포를 살펴볼 예정)

4. ‘모두 고르시오’ / ‘정답 없음’ 문제로 변형 시 정답률 차이 실험

연구 진행상황

선지 수에 따른 정답 확률 변화 실험

- 선지 수를 $n = 4, 5, 10, 20$ 으로 변화시키며, 정답률 변화를 살펴봄.
- n 개 선지에 대해서는 n 번 문제를 풀림.
- 선지가 ≥ 20 이후부터는 정답률이 0.5 미만으로 급감.



model: gemini-2.5-pro

	question	answer_sentence	trial_num	gold	response	response_raw	is_correct	choice_1	choice_2
0	다음 중 맞춤법이 옳바르지 않은 문장은?	시골에 내려가서 부모님께 큰절 커녕 인사도 제대로 못 드리고 왔다.	1	2	틀린 문장: 시골에 내려가서 부모님께 큰절 커녕 인사도 제대로 못 드리고 왔다.\n...	True	버스가 정차하기도 전에 사람들은 차 앞으로 달려들었다.	시골에 내려가서 부모님께 큰절 커녕 인사도 제대로 못 드리고 왔다.	눈만 오아이를
1	다음 중 맞춤법이 옳바르지 않은 문장은?	시골에 내려가서 부모님께 큰절 커녕 인사도 제대로 못 드리고 왔다.	2	1	틀린 문장: 시골에 내려가서 부모님께 큰절 커녕 인사도 제대로 못 드리고 왔다.\n...	True	시골에 내려가서 부모님께 큰절 커녕 인사도 제대로 못 드리고 왔다.	마당에서 피운 불이 울타리에까지 번져 아이들은 화들짝 놀라 야단법석을 떨었다.	정밀하소리 같
2	다음 중 맞춤법이 옳바르지 않은 문장은?	시골에 내려가서 부모님께 큰절 커녕 인사도 제대로 못 드리고 왔다.	3	2	틀린 문장: 시골에 내려가서 부모님께 큰절 커녕 인사도 제대로 못 드리고 왔다.\n...	True	그는 어머니에게 전적으로 믿어지는 든든한 아들이다.	시골에 내려가서 부모님께 큰절 커녕 인사도 제대로 못 드리고 왔다.	철성이려져
3	다음 중 맞춤법이 옳바르지 않은 문장은?	시골에 내려가서 부모님께 큰절 커녕 인사도 제대로 못 드리고 왔다.	4	1	틀린 문장: 시골에 내려가서 부모님께 큰절 커녕 인사도 제대로 못 드리고 왔다.\n...	True	시골에 내려가서 부모님께 큰절 커녕 인사도 제대로 못 드리고 왔다.	넓은 잔디에 군데군데 심은 노랑 팬지꽃이 수많은 나비 떼가 내려앉아 날개를 펴고 있...	그는

향후 계획

- 앞서 언급했던 실험까지 마무리 후 페이퍼 작성 예정.
- EACL 2026 SRW 제출 목표

THOHOI

감사합니다