

CUAI NLP Research 2팀

2025.11.25

발표자: 이나현

팀 소개

이나현
조민지
태아카

100지선다 MCQA

- MCQA의 태생적 한계: 객관식 문제는 찍어서 맞출 확률이 존재함 (예: 4지선다 → 25%).
- Long-form의 한계: 자유서술형 문제는 평가가 어렵고 자동 채점이 까다로움.
- 핵심 아이디어:
만약 MCQA의 선지를 100개 이상으로 늘리면, "찍기"를 통한 정답 확률이 극도로 낮아지면서 사실상 Long-form에 가까운 자유도를 확보할 수 있지 않을까?

실험 계획

1 선지 수에 따른 정답 확률 변화 실험

- 선지 수를 $n = 4, 10, 20, 50, 100$ 으로 변화시킴.
- 무작위 추측 시 한 번 또는 k 번 시도에서의 정답 확률 비교
- 선지 수가 많아질수록 정답 확률은 급감하지만, 여러 시도 시 동일 확률을 유지할 수 있는지 비교.

2 정답 위치(인덱스)에 따른 정답률 편향 실험

- 정답이 선지 1번, 12번, 50번, 99번 등 위치에 따라 정답률이 달라지는가?
- 인간 혹은 모델 응답자들이 특정 위치(앞쪽, 중간, 끝)에 심리적 편향을 가지는지 측정.

3 선지 순서 랜덤화의 영향 실험


- 정답 고정 / 나머지 선지를 섞기
- 순서만 다를 때 정확도가 통계적으로 유의미하게 달라지는가 분석.

100지선다 MCQA

MCQA (Multiple Choice Question answering)

- 객관식 문제 (4지선다, 5지선다 ...)
- MCQA의 태생적 한계: 객관식 문제는 찍어서 맞출 확률이 존재함 (예: 4지선다 → 25%).
- Long-form의 한계: 자유서술형 문제는 평가가 어렵고 자동 채점이 까다로움.

과연 객관식의 비용(0)으로 주관식 만큼의 신뢰도를 얻을 순 없을까?



100지선다 MCQA

Research Goal

→ 선지를 100개까지 늘려서, 찍어서 맞출 확률을 최소화하면서 채점의 효율성을 최대화해보기

Pushing the Boundaries of Multiple Choice Evaluation to One Hundred Options

Pushing the Boundaries of Multiple Choice Evaluation to One Hundred Options

Anonymous ACL submission

Abstract

1 Introduction

Multiple-choice question answering (MCQA) stands as a cornerstone evaluation paradigm in natural language processing (NLP), encompassing diverse domains such as reading comprehension, commonsense reasoning, mathematics, and multi-lingual understanding (Hendrycks et al., 2020; Lai et al., 2017; Ling et al., 2017; Talmor et al., 2019; Zellers et al., 2019). Despite these merits, traditional MCQA formats (typically $N \leq 5$) suffer from a critical *reliability bottleneck*, in which high random-guessing probabilities (e.g., 25%) and the effectiveness of elimination strategies allow models to inflate scores without possessing precise knowl-

In this work, we introduce a robust evaluation protocol applied to Korean Orthography—a domain requiring fine-grained linguistic knowledge. Our contributions are threefold:

1. **Stochastic Evaluation Protocol:** We propose a randomized subsampling method that dynamically generates distractor sets from a large pool. This approach controls for distractor difficulty and marginalizes positional biases, ensuring that score variations reflect only the model's retrieval capability.
2. **Score Purification:** We demonstrate that scaling N from 4 to 100 reveals the "true knowledge boundary." The observed drop in accuracy is not a performance degradation, but the removal of the "guessing bubble," providing a

대규모 선지 확장을 통한 LLM 객관식 평가의 거품 제거와 '진짜 실력' 측정

→ 이제 모델은 소거법 사용 불가.

100개 중에서 진짜 정답을 찾아내는 '정밀 탐색' 능력만이 요구됨

연구 계획

데이터셋 확보

- 네이버사전, 국립국어원 등 국어사전에서 예문을 모아 맞춤법이 완벽한 총 500개 선지 마련.
- 이 중, 10% (약 50개) 선지의 맞춤법을 조금씩 변형함.
- 데이터셋의 정확도를 확보하기 위해, 3개의 다른 맞춤법 검사기 + LLM의 검증 진행
→ 결론적으로 총 450개의 맞춤법이 ‘옳은 문장’과 50개의 ‘옳지 않은 문장’ 생성.

⋮ 다음 중 맞춤법이 옳은 문장은? / 옳지 않은 문장?

1. 병원 측은 더 이상의 방법이 없다며 나머지는 하늘에 맡기자고 했다.
2. 이 제품은 다른 나라에서 만든 수입품보다 품질이 월등히 우수하다.
3. 하지만 마약의 익명성과 은폐성을 고려할 때 실제 중독자 수는 40배에 이를 것으로 추산되고 있습니다.
4. 그 사내는 입고 있는 옷이며, 얼굴에 난 사마귀, 손에 있는 흉터까지 우리 형하고 똑같았다.
5. 가위에 눌린 그는 꿈에서 깨어나기 위해 엄지발가락을 움짱대기 시작했다.
6. 그녀는 친구에게 자신의 일기를 내보이며 자신의 속마음을 전하려 했다.
7. 눈만 오면 강아지처럼 쏘다니던 동네 아이들도 별 수 없이 집 안에 갇혀 창밖만 바라보고 있었습니다.
8. 대통령제는 행정부와 입법부를 분리시켜 대등한 관계를 유지하는 이른바 견제와 균형의 원칙에 충실한 제도인

연구 계획

사용 모델


- Gemini-2.5-flash, Gemini-2.5-pro, Gemini-3-pro-preview
- GPT-4o, GPT-4.1
- Qwen3-30b-instruct
- HyperCLOVAX-SEED-Think-14B
- Kanana-15.7B-instruct
- Exaone4-32B

실험 결과

선지 수에 따른 정답 확률 변화 실험


- 선지 수를 $n = 4, 5, 10, 20, 30, 40, 50, 70, 100$ 으로 변화시킴.
- 선지 수 만큼의 n 번 시도에서의 정답 확률 비교
- 선지 수가 많아질 때, 여러 번의 시도 시 선지 수와 상관 없이 동일 확률을 유지할 수 있는지 비교

실험 결과




• Green: GPT-4.1 / Pink: GPT-4o

실험 결과




Exaone4-32b



HyperclovaX-think-14b

실험 결과



Green: gemini-2.5-flash / Pink: gemini-2.5-pro / Blue: gemini-3-pro-preview


실험 결과

🤔 모집단이 500개니까 샘플링 오류를 피해갈 수 없지 않을까..?

- 4, 5, 10지선다 등의 경우 시도 횟수(샘플링 횟수)가 ≤ 10 이기 때문에, 100지선다에 비해 '옳은 선지'들의 난이도를 통제하기 어려울 것.
- 모든 선지 개수에 대해 100회씩 실험이 필요할 것 같아서 진행중.

실험 결과

모든 선지의 경우의 수 ($N=4,5,\dots,100$)에 대해 100번씩 문제를 풀려본 결과 → 전반적인 정답률 감소




Green: GPT-4.1 / Pink: GPT-4o

실험 결과


🤔 Positional bias..

Gemini 계열은 positional bias X. Gemini-3-pro-preview는 아예 없는 수준

다만 GPT를 비롯한 다른 모델들에서는 positional bias가 아주 심해서, 관련된 스토리텔링을 어떻게 할 건지에 대해 고민중



Gemini-2.5-flash



GPT-4o

Green: gold answer / Pink: model response

향후 계획

- 약 한달 남은 EACL 2026 SRW 제출을 꼭 해보겠습니다

THOHOI

감사합니다